MÉTODOS E TÉCNICAS DE PESQUISA · PPGCC 0002 · MESTRADO

Aula 9 — Experimentos, Estudos de Caso e Ética

Experimentos e estudos de caso em Ciência da Computação; ética em pesquisa e uso responsável de dados

ROTEIRO DA AULA

O que vamos fazer hoje

1. **Abertura e ativação**
   Recapitulação e aquecimento
2. **Bloco 01**
   Pesquisa experimental em CC, aprofundada
3. **Bloco 02**
   Estudos de caso em CC
4. **Intervalo — 30 minutos**
   Pausa entre os blocos
1. **Bloco 03**
   Ética em pesquisa
2. **Bloco 04**
   Uso responsável de dados
3. **Síntese do dia**
   Como tudo se conecta
4. **Encerramento**
   Tarefa para levar + próxima aula

RECAPITULANDO

O caminho até aqui

Aula 7 — Tipos e abordagens

- Pesquisa experimental já apareceu como um dos procedimentos técnicos (Gil, 2010) — vimos o conceito básico.
- Abordagens qualitativa, quantitativa e mista — toda pesquisa precisa escolher um delineamento coerente com elas.

Aula 8 — Amostragem e coleta

- Quem vamos estudar (amostragem) e como vamos coletar dados (entrevistas, questionários, observação).
- Hoje: como organizar a coleta em um delineamento rigoroso — experimento ou estudo de caso — e com responsabilidade ética.

Hoje aprofundamos o "como" da pesquisa empírica em Computação — e tratamos do "com que responsabilidade".

POR QUE ISSO IMPORTA

Isso vira parte do seu Projeto de Qualificação

> *Toda dissertação empírica em Computação precisa responder: que delineamento escolhi (experimento ou estudo de caso) e por quê? Como vou lidar, com responsabilidade, com os dados e as pessoas envolvidas?*

PONTE DIRETA

Essas respostas alimentam diretamente a Seção de Metodologia e a Seção de Aspectos Éticos do seu Projeto de Qualificação. Bancas examinadoras cobram isso com frequência.

OBJETIVOS DE APRENDIZAGEM

Ao final desta aula, você será capaz de...

1. **Delinear um experimento em Computação**
   Identificar hipótese, variáveis independente/dependente e ameaças à validade.

2. **Reconhecer quando um estudo de caso é a escolha certa**
   E desenhar seus elementos essenciais (unidade de análise, fontes de evidência).

3. **Aplicar princípios éticos à sua própria pesquisa**
   Consentimento, CEP/CONEP, LGPD: sem depender de decorar a lei.

4. **Avaliar se um dataset pode ser usado com responsabilidade**
   Com um checklist prático, aplicável já ao seu projeto de dissertação.

PARA COMEÇAR

Ativação inicial

PARTICIPAÇÃO EM SALA

VOTO COM OS PÉS (DESLOCAMENTO EM SALA)

Seu projeto é mais parecido com um experimento ou um estudo de caso?

Vamos usar o espaço da sala: um lado representa "experimento", o outro "estudo de caso". Sem pensar demais — vá com a primeira impressão sobre o seu próprio tema de dissertação.

1. Levante-se e vá para o lado da sala que combina mais com a sua pesquisa (ou o meio, se estiver em dúvida).
2. 2-3 pessoas de cada lado explicam em 1 frase por que escolheram esse lado.
3. Guarde sua posição na cabeça — vamos retomar essa pergunta no fim da aula, com mais ferramentas para responder.

BLOCO 01 · APROFUNDANDO A AULA 7

Pesquisa Experimental em Ciência da Computação

Da ideia geral de "pesquisa experimental" (Aula 7) para o desenho rigoroso de um experimento: hipótese, variáveis, controle e validade.

O que já vimos — e o que vamos aprofundar

Já vimos (Aula 7)

A pesquisa experimental é um procedimento técnico que testa relações de causa e efeito, manipulando deliberadamente uma variável para observar o efeito em outra.

Vamos aprofundar hoje

Como desenhar um experimento de verdade: hipótese testável, variáveis, grupos de controle e tratamento, randomização e como reconhecer quando ele está mal desenhado.

A anatomia de um experimento

Hipótese testável

Uma afirmação que pode ser refutada por dados (lembra Popper, Aula 3) — ex.: "o algoritmo A tem CTR (Click-Though Rate- taxa de cliques) maior que o algoritmo B".

Variável Independente (VI)

O que o pesquisador manipula deliberadamente — ex.: qual algoritmo de recomendação é mostrado ao usuário.

Variável Dependente (VD)

O que se mede como resultado — ex.: taxa de cliques, tempo de resposta, taxa de erro.

Grupo controle × grupo de tratamento

Controle recebe a condição atual/padrão; tratamento recebe a condição nova que está sendo testada.

Randomização

Atribuir sujeitos aos grupos por sorteio — é o que permite atribuir causalidade ao resultado, não a diferenças entre os grupos.

Três formas de organizar um experimento

Between-subjects (entre sujeitos)

- Grupos diferentes de sujeitos, cada grupo vê só uma condição.
- Ex.: grupo A usa a IDE X, grupo B usa a IDE Y.
- Evita efeito de aprendizado entre condições.
- Precisa de mais sujeitos no total.

Within-subjects (dentro do sujeito)

- O mesmo grupo passa por todas as condições.
- Ex.: o mesmo dev usa a IDE X e depois a IDE Y.
- Precisa de menos sujeitos.
- Risco: efeito de ordem/aprendizado — contrabalançar a ordem.

Fatorial

- Duas ou mais variáveis independentes combinadas.
- Ex.: algoritmo (A/B) × tamanho do dataset (pequeno/grande).
- Revela interações entre variáveis.
- Mais complexo de analisar (ponte com a Aula 10).

Between-subjects: cada grupo vê só uma condição

Como funciona

Os sujeitos são divididos, por sorteio (randomização), em grupos diferentes. Cada grupo passa por apenas UMA versão da variável independente — ninguém experimenta mais de uma condição.

Exemplo em CC

Comparar 2 interfaces (A e B) de um app. 40 participantes são sorteados em 2 grupos de 20. O Grupo 1 usa só a interface A; o Grupo 2, só a B. Ambos realizam as mesmas 5 tarefas. Variável Dependente: número de erros cometidos.

Vantagens

- Elimina o efeito de ordem/aprendizado — ninguém passa por mais de uma condição.
- Mais simples de analisar (ex.: teste t para grupos independentes).

Cuidados

- Precisa de mais participantes — cada grupo precisa ser grande o suficiente.
- Risco de viés de seleção se a randomização não for bem feita.

Within-subjects: o mesmo grupo passa por todas as condições

Como funciona

O mesmo grupo de sujeitos passa por TODAS as condições da variável independente, em sequência. Cada pessoa funciona como seu próprio controle — a comparação é feita dentro do mesmo indivíduo.

Exemplo em CC

Comparar 2 ferramentas de debug (X e Y). Os mesmos 15 desenvolvedores depuram um bug com X e, depois, outro bug equivalente com Y, em ordem contrabalançada. Variável Dependente: tempo até encontrar o bug.

Vantagens

- Precisa de muito menos participantes — cada um gera dados para todas as condições.
- Elimina a variabilidade entre indivíduos — mais sensível a efeitos pequenos.

Cuidados

- Risco de efeito de ordem — mitigado contrabalançando a ordem das condições.
- Risco de fadiga acumulada e de efeito de carryover (quando a experiência de uma condição “vaza” e contamina o resultado da condição seguinte) entre condições.

Fatorial: duas ou mais variáveis combinadas ao mesmo tempo

Como funciona

Duas ou mais variáveis independentes são manipuladas simultaneamente, combinadas entre si. Além do efeito de cada variável isolada, revela a INTERAÇÃO entre elas — como uma afeta o efeito da outra.

Exemplo em CC

Desenho 2×2: Algoritmo de recomendação (A/B) × Tamanho do catálogo (pequeno/grande) = 4 grupos. VD: engajamento (CTR). Pode revelar que A só supera B quando o catálogo é grande — uma interação real.

Vantagens

- Revela interações entre variáveis, não só efeitos isolados.
- Mais eficiente que rodar experimentos separados para cada variável.

Cuidados

- Cresce rápido em número de grupos — um fatorial 2×2×2 já são 8 condições.
- Análise mais complexa (ANOVA fatorial) — aprofundaremos na Aula 10.

Ameaças à validade interna: o que pode enganar você

- Viés de seleção: os grupos eram diferentes desde o início (ex.: só voluntários entram no grupo tratamento).
- Maturação / efeito de ordem: sujeitos melhoram só por repetição ou pelo tempo, não pela condição testada.
- História: algo externo aconteceu entre as medições e afetou só um dos grupos (ex.: condições de rede diferentes).
- Instrumentação / viés do avaliador: o próprio instrumento de medição ou quem avalia influencia o resultado.
- Mortalidade experimental: sujeitos desistem de forma desigual entre os grupos, distorcendo a comparação final.

Três outros tipos de validade a verificar

Validade externa

O resultado generaliza para fora do laboratório? Uma amostra só de estudantes de uma turma generaliza para desenvolvedores profissionais?

Validade de construto

A medida usada realmente mede o que você diz que está medindo? "Produtividade" medida só por linhas de código é um construto frágil.

Validade de conclusão estatística

A amostra é grande e representativa o bastante e a análise é adequada para sustentar a conclusão? Aprofundaremos isso na Aula 10.

Um experimento inteiro, passo a passo

EXEMPLO DE CIÊNCIA DA COMPUTAÇÃO

Um novo algoritmo de recomendação aumenta o engajamento?

Hipótese: usuários expostos ao algoritmo A (novo) terão taxa de cliques (CTR) maior que os expostos ao algoritmo B (atual). VI: qual algoritmo é mostrado (A ou B). VD: taxa de cliques. Grupo controle: usuários no algoritmo B. Grupo tratamento: usuários no algoritmo A. Randomização: cada usuário é atribuído a A ou B por sorteio, ao entrar no sistema (um teste A/B clássico). Ameaças controladas: os dois grupos rodam no mesmo período (evita a ameaça de "história"/sazonalidade) e a amostra é grande o suficiente para sustentar conclusão estatística.

E as pessoas no experimento?

CUIDADO ESSENCIAL

Um experimento com seres humanos levanta perguntas que um experimento só com algoritmos não levanta: o grupo controle pode ficar em desvantagem? As pessoas sabem que estão participando de um teste? Isso é consentimento informado — tema do Bloco 03 desta aula.

> *Delineamento rigoroso e ética não são etapas separadas — um experimento tecnicamente perfeito, mas conduzido sem consentimento, não é um bom experimento de pesquisa.*

SÍNTESE · BLOCO 01

Antes de seguir: o teste da coerência

> *Se você consegue manipular deliberadamente uma variável e controlar as condições — você provavelmente tem um experimento. Se não, talvez o seu caminho seja o estudo de caso, que veremos agora.*

BLOCO 02

Estudos de Caso em Ciência da Computação

Quando o pesquisador não controla as variáveis, mas quer entender em profundidade um fenômeno real, em seu contexto real.

O que é um estudo de caso?

Definição (Yin, 2015)

Investigação empírica que estuda um fenômeno contemporâneo em profundidade, dentro do seu contexto de vida real — especialmente quando os limites entre fenômeno e contexto não são claros.

Quando usar

A pergunta é "como" ou "por quê"; o pesquisador tem pouco ou nenhum controle sobre os eventos; o foco é um fenômeno atual, não histórico.

Atenção

"Estudo de caso" não é sinônimo de "exemplo" ou "estudo pequeno" — é um delineamento de pesquisa com elementos de design próprios (Runeson & Höst, 2009).

Tipos de estudo de caso

Exploratório

Quando pouco se sabe ainda sobre o fenômeno — ajuda a gerar hipóteses e refinar a questão de pesquisa.

Descritivo

Descreve o fenômeno em detalhe, no seu contexto real, sem necessariamente explicar causas.

Explanatório

Busca explicar relações causais em um contexto real complexo, onde um experimento controlado não seria viável.

Caso único × casos múltiplos

Caso único: revelador, crítico ou extremo. Casos múltiplos: permitem comparação e replicação das conclusões.

Os elementos de um bom design de estudo de caso

1. **Questões do estudo**
   Perguntas "como" ou "por quê" bem delimitadas, que guiam toda a coleta.

2. **Unidade(s) de análise**
   O que exatamente é "o caso"? Uma equipe, um projeto, uma organização, um repositório?

3. **Proposições teóricas (se houver)**
   O que você espera encontrar, com base na teoria — direciona onde olhar.

4. **Fontes de evidência e triangulação**
   Entrevistas, documentos, observação, artefatos (repositórios, logs) — cruzadas entre si.

5. **Critérios para interpretar os achados**
   Como você vai saber se encontrou um padrão relevante, e não ruído.

Como saber se um estudo de caso é rigoroso

Validade

- De construto: múltiplas fontes de evidência (triangulação) e um encadeamento claro de evidências.
- Interna (só para explanatórios): a lógica causal proposta realmente se sustenta nos dados coletados?
- Externa: generalização analítica — para a teoria, não para uma população (diferente do experimento).

Confiabilidade

- Um protocolo de estudo de caso documentado, que outro pesquisador poderia seguir.
- Um banco de dados do caso organizado (entrevistas, documentos, notas de campo).
- Isso permite que outra pessoa audite — mesmo sem repetir — o seu processo de pesquisa.

Generalização analítica (para a teoria) é diferente de generalização estatística (para a população) — não confunda as duas.

VALIDADE EXTERNA · COMPLEMENTO

Generalizar para quem? Duas lógicas bem diferentes

Experimento → generalização estatística

- A amostra é extraída (idealmente por sorteio) de uma população maior, para poder calcular margem de erro.
- Pergunta respondida: esse resultado vale, nessa proporção, para a população toda?
- Exemplo: testar 40 devs sorteados de um perfil → inferir estatisticamente sobre todos os devs daquele perfil.

Estudo de caso → generalização analítica

- O caso é escolhido por ser relevante ou revelador, não por representar estatisticamente uma população.
- Pergunta respondida: esse caso confirma, refina ou desafia uma teoria?
- Exemplo: 1 empresa que adotou DevOps → sustenta uma teoria sobre resistência organizacional à mudança.

Replicação lógica (Yin, 2015): um próximo caso bem escolhido fortalece a teoria — não "aumenta a amostra" como em um experimento.

Um estudo de caso inteiro, passo a passo

EXEMPLO DE CIÊNCIA DA COMPUTAÇÃO

Como uma equipe de desenvolvimento adotou DevOps?

Unidade de análise: a equipe de desenvolvimento de uma única empresa de médio porte. Tipo: descritivo/explanatório (como e por que a adoção teve sucesso parcial). Fontes de evidência: 12 entrevistas com desenvolvedores, documentos internos de processo, métricas reais de frequência de deploy (triangulação). Generalização: analítica — os achados dialogam com a teoria de adoção de práticas ágeis, não afirmam que "toda empresa" teria o mesmo resultado. Duração do acompanhamento: 8 meses, sem interferência do pesquisador nos processos reais da equipe.

BLOCO 02 · SÍNTESE

Experimento × Estudo de caso × Levantamento

Experimento

- Controle: alto — manipula variáveis.
- Foco: condições controladas.
- Pergunta típica: "o quê causa o quê?"
- Generalização: estatística, para a população.

Estudo de caso

- Controle: nenhum ou baixo.
- Foco: fenômeno real, no seu contexto.
- Pergunta típica: "como e por quê?"
- Generalização: analítica, para a teoria.

Levantamento (survey)

- Controle: nenhum.
- Foco: um momento específico (corte transversal).
- Pergunta típica: "quantos, quais, com que frequência?"
- Generalização: estatística, se a amostra for probabilística (Aula 8).

BLOCO 02 · PRÁTICA

Dinâmica: Experimento, estudo de caso ou levantamento?

PARTICIPAÇÃO EM SALA

Kahoot

Classifiquem 6 cenários de pesquisa em CC (Kahoot)

SÍNTESE · BLOCO 02

A escolha metodológica é só o começo

RETOMANDO A ATIVAÇÃO INICIAL

Agora que vimos os critérios com mais precisão: você mudaria de lado na sala? O importante não é "acertar de primeira", é saber justificar a escolha com os elementos que vimos hoje.

> *Seja qual for a escolha — experimento ou estudo de caso — ela envolve pessoas e dados reais. É disso que trataremos depois do intervalo.*



Uma pausa antes de continuar

Voltamos em 30 minutos

BLOCO 03

Ética em Pesquisa

Experimentos e estudos de caso envolvem pessoas e dados reais — e isso exige princípios, não só boas intenções.

BLOCO 03 · ÉTICA EM PESQUISA

Por que parar para falar de ética, justo agora

> *Todo experimento envolve pessoas (usuários, desenvolvedores, participantes). Todo estudo de caso envolve organizações e indivíduos reais. A pesquisa em Computação também lida com dados — e dados são, cada vez mais, sobre pessoas.*

ANTES DE CONTINUAR

Ética em pesquisa não é um capítulo separado da metodologia — é um critério que atravessa toda escolha metodológica que fizemos até agora.

Três princípios que fundamentam a ética em pesquisa

Respeito à autonomia

As pessoas decidem, de forma livre e informada, se participam da sua pesquisa. Ninguém participa "sem saber".

Beneficência

Maximizar benefícios e minimizar danos possíveis às pessoas envolvidas — incluindo danos indiretos, como exposição de dados.

Justiça

Os ônus e os benefícios da pesquisa devem ser distribuídos de forma justa — ninguém deve arcar com o risco sem nenhum benefício possível.

Relatório Belmont (1979) — referência fundadora da ética em pesquisa com seres humanos.

Consentimento informado: o que precisa conter

- O objetivo real da pesquisa, em linguagem acessível — sem esconder nem "vender" demais.
- Os procedimentos: o que a pessoa vai fazer, por quanto tempo, com que frequência.
- Riscos e benefícios possíveis, mesmo que pequenos ou indiretos.
- Como a confidencialidade e os dados coletados serão protegidos.
- O direito de desistir a qualquer momento, sem nenhum prejuízo.
- Um contato — do pesquisador e, quando aplicável, do Comitê de Ética (CEP).

Quando submeter ao Comitê de Ética (CEP)

NA PRÁTICA

CEP/CONEP e Plataforma Brasil

Pesquisa que envolve, direta ou indiretamente, seres humanos — inclusive por meio de dados sobre pessoas — em regra precisa ser submetida a um Comitê de Ética em Pesquisa (CEP), via Plataforma Brasil, conforme a Resolução CNS 466/2012. O prazo de análise varia (semanas a meses) — por isso essa submissão precisa ser planejada com antecedência, não na véspera da coleta de dados. Se o seu projeto envolve entrevistas, questionários, observação de pessoas ou dados pessoais, essa é uma pergunta que a sua Seção de Metodologia do Projeto de Qualificação já deve responder.

LGPD aplicada à pesquisa: dois conceitos que não são sinônimos

Anonimização

- Processo irreversível: não é mais possível identificar a pessoa, nem combinando com outras bases.
- Um dado verdadeiramente anonimizado deixa de ser considerado "dado pessoal" pela LGPD.
- Na prática, é mais difícil de garantir do que parece — reidentificação por cruzamento de bases é um risco real.

Pseudonimização

- Processo reversível: os identificadores são trocados por códigos, mas existe uma chave que permite reverter.
- Ainda é considerado "dado pessoal" pela LGPD — exige as mesmas proteções.
- Muito usada em pesquisa longitudinal, onde é preciso reidentificar o mesmo participante depois.

Lei 13.709/2018 (LGPD) — pesquisa acadêmica tem base legal própria, mas isso não dispensa proteger os dados.

Integridade científica: revisão rápida

Plágio

Apresentar ideias, texto ou dados de outra pessoa como se fossem seus, sem atribuição.

Fabricação e falsificação

Inventar dados que nunca foram coletados, ou alterar resultados reais para "funcionarem melhor".

Autoria indevida

Incluir (ou excluir) autores que não contribuíram (ou que contribuíram) de forma substancial.

Duplicidade de publicação

Publicar essencialmente o mesmo trabalho em mais de um veículo, sem declarar isso.

Uso responsável de dados: o que é específico de Computação



Viés em datasets

Um conjunto de dados pode refletir desigualdades históricas — um modelo treinado nele pode reproduzir ou amplificar essas desigualdades (justiça algorítmica).



Scraping e Termos de Uso

Dados "publicamente visíveis" não são automaticamente livres de restrições éticas ou legais — os Termos de Uso da plataforma de origem importam.



Reidentificação

Mesmo dados "anonimizados" de forma ingênua podem reidentificar pessoas ao serem cruzados com outras fontes.

BLOCO 03 · PARA REFLETIR

Um dilema real de pesquisa em CC

?

SITUAÇÃO PARA REFLEXÃO

Esse dataset está "público" — posso simplesmente usar?

Um mestrando encontra, em um repositório aberto, um dataset de mensagens de um fórum de saúde mental, coletado por scraping, sem consentimento explícito dos usuários — mas tecnicamente "público". Ele quer usá-lo para treinar um classificador de risco de crise emocional. O fato de estar disponível publicamente resolve, por si só, a questão ética? Que riscos existem, mesmo com dados anonimizados? O que ele deveria verificar antes de seguir em frente? Vamos analisar esse e outro dilema a seguir.

BLOCO 03 · DILEMA ÉTICO · REFLEXÃO EM TURMA

Dilema 1 — Dataset público e sensível

SITUAÇÃO

Um mestrando encontra, em um repositório aberto, um dataset de mensagens de um fórum de saúde mental, coletado por scraping, sem consentimento explícito dos usuários — mas tecnicamente "público". Ele quer usá-lo para treinar um classificador de risco de crise emocional.

1

O fato de estar disponível publicamente resolve, por si só, a questão ética?

Não. 'Público' não é o mesmo que consentido — dado de saúde mental é sensível (LGPD) e pode exigir aprovação do CEP/CONEP mesmo sendo preexistente.

2

Que riscos de reidentificação ou dano existem mesmo com dados anonimizados?

Sim há risco: estilo de escrita e detalhes do relato podem reidentificar, mesmo sem nome; e expor relatos de crise já é um dano, independente de reidentificação.

3

O que o pesquisador deveria verificar antes de usar esse dataset?

Termos de uso do fórum, aprovação em CEP/CONEP, base legal na LGPD, e se já existe um dataset revisado eticamente para esse fim.

Dilema 2 — Scraping para treinar modelo

SITUAÇÃO

Uma equipe de pesquisa faz scraping de milhares de perfis públicos de uma rede social para treinar um modelo de IA generativa, violando os Termos de Uso da plataforma — mas sem coletar dados "sensíveis" (só texto público).

1. **Violar os Termos de Uso de uma plataforma é um problema ético, mesmo com dados "públicos"?**
   Sim — é quebra contratual (risco jurídico) e ultrapassa a escala de uso que o usuário imaginava ao aceitar os Termos.

2. **Como isso se relaciona com consentimento informado?**
   O usuário consentiu com a visualização por outros na plataforma, não com seus dados virando treino de IA — viola o princípio de autonomia (Belmont).

3. **Que alternativas mais responsáveis existem para obter dados de treinamento?**
   API oficial com termos para pesquisa, datasets já curados e liberados, parceria/opt-in, ou dados sintéticos — sempre documentando a escolha.

ÉTICA E IA GENERATIVA NA PESQUISA

IA não é autora — e você responde por tudo que ela produz

Consenso internacional

Para o COPE e o ICMJE, a IA não pode ser autora: não assume responsabilidade, não declara conflito de interesse, não detém direitos autorais. O uso deve ser declarado no artigo.

No Brasil (CNPq)

A Portaria CNPq 2.664/2026 não proíbe o uso, mas exige declarar a ferramenta e a finalidade. Apresentar texto da IA como autoria humana é vedado.

REGRA PRÁTICA

Declare o uso, verifique tudo o que a IA produzir, e lembre: a responsabilidade final por erros, plágio ou dados fabricados é sempre sua — nunca da ferramenta.

COPE (2023); ICMJE (2024); CNPq, Portaria nº 2.664, de 6 de março de 2026.

Cuidado: IA pode inventar referências que parecem reais

Alucinação: a IA gera referências com título, autores e ano que soam reais, mas não existem, ou atribui a um estudo real conclusões que ele nunca afirmou.

- Caso jurídico Mata v. Avianca (EUA, 2023): advogados usaram ChatGPT e citaram casos judiciais inexistentes — multa de US$ 5.000.
- Journal of Academic Ethics (Springer Nature, abril/2025): artigo publicado com 19 de 29 referências fabricadas; autor admitiuter usado ChatGPT.
- Auditorias recentes (2025): ~147 mil citações "alucinadas" em 111 milhões de referências, e ~2% dos artigos aceitos na NeurIPS 2025 traziam citação fabricada confirmada.

REGRA PRÁTICA

Nunca cite uma referência sugerida pela IA sem abrir o artigo original e confirmar que ele existe.

Mata v. Avianca (2023); Retraction Watch (dez/2025); GPTZero/NeurIPS (2025); auditoria de 111M referências (2025-2026).

Uso apropriado × uso que vira problema de integridade

Apropriado — declarado e verificado

- Revisão de texto, gramática e clareza da escrita.
- Brainstorm e apoio em busca bibliográfica.
- Assistência de código, sempre revisada por você.

Vira problema de integridade

- Fabricar dados, resultados ou citações.
- Citar referência da IA sem checar se existe.
- Submeter texto da IA como análise 100% sua, sem revisão.

No CNPq, o uso de IA generativa deve ser declarado (ferramenta + finalidade) — ligue isso à Seção de Metodologia do seu Projeto de Qualificação.

COPE (2023); ICMJE (2024); CNPq, Portaria nº 2.664, de 6 de março de 2026.

SÍNTESE · BLOCO 03

Ética não é uma caixa a marcar no final

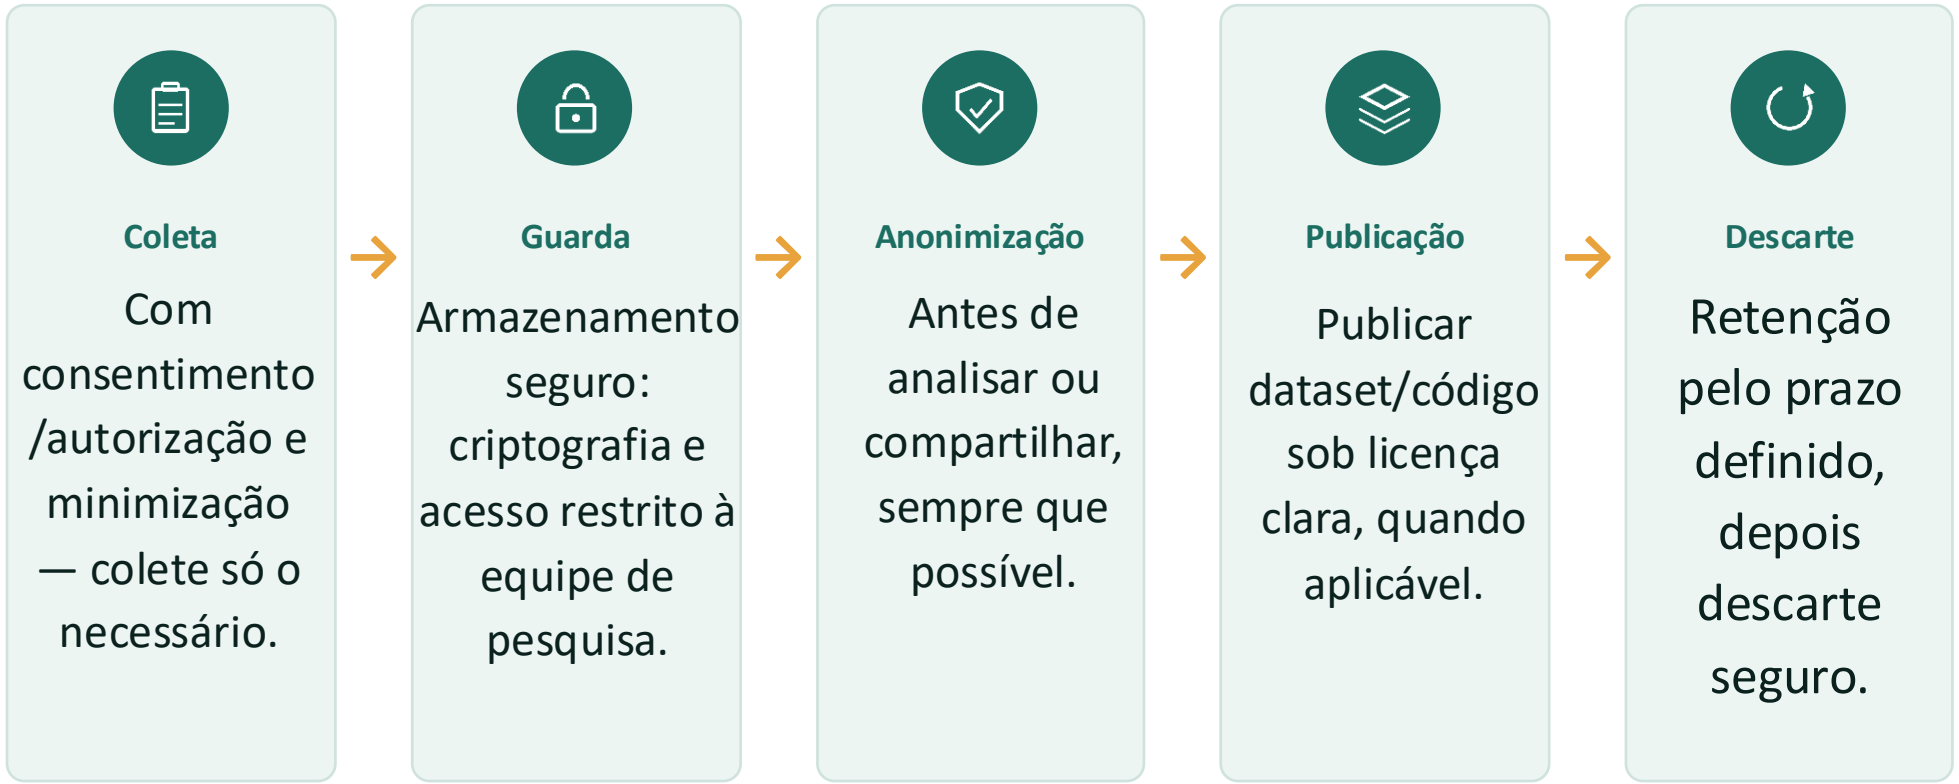
> *Consentimento, CEP, LGPD e uso responsável de dados precisam ser pensados quando você desenha o experimento ou o estudo de caso — não depois que os dados já foram coletados.*

BLOCO 04

Uso Responsável de Dados na Pesquisa

Da coleta ao descarte: como tratar dados de pesquisa do início ao fim do ciclo de vida.

O ciclo de vida responsável dos dados de pesquisa



Checklist: antes de usar esse dataset

- Os dados foram coletados/publicados com consentimento ou autorização legítima (inclusive Termos de Uso)?
- Há dados pessoais identificáveis? Foram anonimizados ou pseudonimizados de forma adequada?
- O uso que você pretende dar é compatível com a finalidade original da coleta?
- Existe risco de reidentificação, mesmo após a anonimização (ex.: cruzamento com outras bases)?
- O dataset tem proveniência documentada — fonte, data, licença — e pode ser citado corretamente?
- Seu projeto, envolvendo esses dados, precisa de submissão ao CEP/CONEP (Plataforma Brasil)?

E se for você publicando o dataset?

Documente a proveniência

De onde vieram os dados, quando, com que autorização e quais transformações foram feitas.

Use uma licença clara

Deixe explícito o que outros pesquisadores podem e não podem fazer com o seu dataset ou código.

Princípios FAIR

Dados que sejam localizáveis, acessíveis, interoperáveis e reutilizáveis — um padrão cada vez mais esperado em CC.

Isso vira a Seção de Aspectos Éticos do seu projeto

PARA O SEU PROJETO DE QUALIFICAÇÃO

Sua Seção de Aspectos Éticos precisa indicar: se o projeto precisa de CEP/CONEP, como o consentimento será obtido (se aplicável), e como os dados serão protegidos e, eventualmente, compartilhados.

> *Quanto mais cedo essa seção for pensada, menos retrabalho você tem depois — alguns cuidados éticos mudam o próprio desenho da coleta.*

BLOCO 04 · PRÁTICA

Aplicando o checklist ao seu próprio projeto

Aplique o checklist ao seu tema de dissertação

Mesmo que você ainda não tenha coletado dados, já dá para prever: que tipo de dado seu projeto vai usar/gerar, e que cuidados da lista anterior já se aplicam a ele.

SÍNTESE DO DIA

Como os 4 blocos se conectam

1. Escolha metodológica

- Experimento: você controla e manipula variáveis.
- Estudo de caso: você observa um fenômeno real, em contexto.
- A escolha depende da sua pergunta de pesquisa.

2. Coleta de dados

- Amostragem, entrevistas, questionários, observação (Aula 8).
- O instrumento de coleta precisa servir à escolha metodológica.

3. Ética, o tempo todo

- Consentimento, CEP/CONEP, LGPD.
- Uso responsável de dados — do planejamento ao descarte.
- Atravessa os dois delineamentos, não é uma etapa à parte.

RECAPITULANDO

O que vimos hoje

1. **Anatomia de um experimento**
   Hipótese, VI, VD, controle, randomização.

2. **Delineamentos experimentais**
   Between-subjects, within-subjects, fatorial.

3. **Ameaças à validade**
   Interna, externa, de construto, de conclusão estatística.

4. **Estudos de caso**
   Definição, tipos, elementos de design, critérios de qualidade.

1. **Experimento × caso × levantamento**
   Quando cada um é a escolha certa.

2. **Princípios éticos (Belmont)**
   Autonomia, beneficência, justiça.

3. **Consentimento, CEP/CONEP, LGPD**
   O que cada um exige na prática.

4. **Uso responsável de dados**
   Ciclo de vida completo + checklist aplicável já.

TAREFA PARA LEVAR

Antes da próxima aula



PARA O SEU PROJETO DE DISSERTAÇÃO

Responda, por escrito, 3 perguntas sobre o seu próprio projeto

1. Seu projeto é mais próximo de um experimento ou de um estudo de caso — e por quê, com os critérios de hoje? 2. Que tipo(s) de dado seu projeto vai coletar ou usar, e quais cuidados éticos (consentimento, anonimização, CEP) já se aplicam? 3. Se seu projeto usa um dataset existente, ele passa no checklist do Bloco 04? Essas respostas alimentam diretamente as Seções de Metodologia e Aspectos Éticos do seu Projeto de Qualificação. Na Aula 10, vamos ver como analisar os dados que você está planejando coletar — qualitativa e quantitativamente.

Obrigada!

REFERÊNCIAS DESTA AULA

WOHLIN, C. et al. Experimentation in Software Engineering: An Introduction. Berlin: Springer, 2012.

YIN, R. K. Estudo de caso: planejamento e métodos. 5. ed. Porto Alegre: Bookman, 2015.

RUNESON, P.; HÖST, M. Guidelines for conducting and reporting case study research in software engineering. Empirical Software Engineering, v. 14, n. 2, p. 131-164, 2009.

Resolução CNS nº 466/2012 — diretrizes e normas de pesquisa envolvendo seres humanos (Plataforma Brasil).

Lei nº 13.709/2018 — Lei Geral de Proteção de Dados Pessoais (LGPD).

GIL, A. C. Como elaborar projetos de pesquisa. 5. ed. São Paulo: Atlas, 2010.